环境科学
Environmental Science
ISSN 0250-3301,CN 11-1895/X

《环境科学》网络首发论文

题目：　中国能源消费与碳达峰预测：融合深度学习的分解-集成模型
作者：　周程，胡斐，王田
DOI：　10.13227/j.hjkx.202511345
收稿日期：　2025-11-26
网络首发日期：　2026-03-05
引用格式：　周程，胡斐，王田．中国能源消费与碳达峰预测：融合深度学习的分解-集成模型[J/OL]．环境科学. https://doi.org/10.13227/j.hjkx.202511345

网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

网络首发时间：2026-03-05 10:09:31　网络首发地址：https://link.cnki.net/urlid/11.1895.X.20260304.1835.023

中国能源消费与碳达峰预测：融合深度学习的分解-集成模型

周程[1]，胡斐[2*]，王田[3]

（1．湖北经济学院工商管理学院，武汉 430205; 2.同济大学电子与信息工程学院，上海 201800; 3．中南财经政法大学工商管理学院，武汉 430073）

摘要：精准预测能源消费与碳排放，是制定科学合理的能源与气候政策的关键依据。提出一种融合深度学习的两层“分解-集成”的能源消费预测方法：首先，通过趋势分解和 EMD 两层分解，从原始能源消费时序数据中提取趋势项和非趋势项的多尺度数据子序列；随后，对趋势序列和非趋势序列分别利用 STIRPAT 模型和灰狼优化（GWO）增强的 LSTM 神经网络模型进行预测；最终集成各成分预测结果，得到能源消费的最终预估值。实证结果表明，融合深度学习技术的两层分解-集成模型能够有效捕捉能源消费序列中趋势项与非趋势项的内在演化规律，其预测精度显著优于对比方法——在平均绝对百分比误差（MAPE）指标上，较 4 种主流竞争模型分别降低 65%、78%、61%和 43%。这不仅验证了该方法在能源消费预测中的有效性与适用性，也为能源相关领域提供了一种更为精准可靠的预测工具。基于上述模型对 2024～2035 年期间中国能源消费及碳达峰时间与峰值开展了多情景预测分析，结果表明：①我国能源消费总量在未来十年内仍将保持增长，但增速显著放缓；②在设定的 4 种多因素耦合情景下中国均能在 2030 年前实现碳达峰，且碳排放总量增速总体趋缓；③能源结构优化与产业结构升级是推动碳达峰的关键因素，能有效提前达峰时间并降低达峰峰值。

关键词：能源消费；碳达峰；预测；深度学习；分解-集成

DOI:10.13227/j.hjkx.202511345

Forecasting China’s Energy Consumption and Carbon Peak Using a Deep Learning-Based Decomposition-Integration Model

Zhou Cheng[1]，Hu Fei[2*]，Wang Tian[3]

（1. School of Business Administration，Hubei University of Economics，Wuhan 430205，China; 2.College of Electronic and Information Engineering, Tongji University, Shanghai, 201800, China; 3.School of Business Administration，Zhongnan University of Economics and Law，Wuhan 430073，China）

Abstract: Accurate forecasting of energy consumption and carbon dioxide emissions is of critical importance, serving as a foundational basis for governments to formulate scientifically sound energy and climate governance policies. This paper introduces a novel two-layer decomposition-integration forecasting framework for energy consumption, which effectively incorporates deep learning techniques. The proposed method applies a two-layer decomposition to the original data series, which extracts multi-scale frequency-domain subsequences corresponding to both the trend component and the non-trend components. Subsequently, the prediction is carried out in a component-specific manner: the trend series is modeled using the STIRPAT framework, while the non-trend series is forecasted by a Long Short-Term Memory (LSTM) neural network, the hyperparameters of which are optimized by the Grey Wolf Optimizer (GWO) algorithm. Finally, the predictions of all individual components are integrated to produce the final energy consumption forecasting results. Empirical results demonstrate that the aboved model successfully captures the intrinsic evolutionary patterns within both trend and non-trend fluctuations. Its predictive accuracy, measured by Mean Absolute Percentage Error (MAPE), shows a marked improvement over several benchmark models, confirming the method's effectiveness and practical applicability in energy consumption forecasting and establishing it as a valuable analytical tool. Leveraging this validated model, we conducted a multi-scenario forecasting analysis for China's energy consumption and its associated carbon emission trajectory from

收稿日期：2025-11-26；**修订日期：**2026-02-03

基金项目：国家自然科学基金项目（72171232）；国家自然科学基金青年科学基金项目（71701073）

作者简介：周程（1978～），博士，教授，主要研究方向为能源经济与碳排路径，E-mail: 59414648@qq.com

*通信作者，E-mail: 1539252442@qq.com

2024 to 2035, focusing on the timing and magnitude of the carbon peak. The key findings are as follows: ① China's total energy consumption is projected to maintain growth over the next decade, albeit with a significantly decelerating rate; ② Under the six defined scenarios, China is expected to achieve its carbon peak before 2030 in most cases, with the overall growth in total emissions exhibiting a general decelerating trend; ③ The optimization of the national energy structure and industrial upgrading are identified as pivotal drivers facilitating an earlier carbon peak, exerting a substantial positive influence on both the peaking timeline and the ultimate peak volume.

Key words: energy consumption; carbon peak; forecast; deep learning; decomposition-ensemble

能源作为连接人类社会与生态系统的关键纽带，不仅是推动人类社会进步的基石，对于推进国家繁荣、民生改善和社会长治久安也具有至关重要的意义[1]。能源的开发利用方式深刻影响着生态平衡、环境质量与全球气候，是推动人类走向可持续发展道路的核心议题。推进能源系统转型、实现可持续能源供应，不断提升人民生活水平，并为世界经济发展注入持久动力，保证人类社会的永续发展，已成为全球广泛认同的发展目标。近年来，伴随经济高速增长，中国能源消耗量与碳排放量也攀升至全球第一，经济发展与环境治理之间的深层次矛盾突出。作为负责任的大国，中国始终倡导人与自然和谐共生，将生态环境保护与治理置于可持续发展的核心位置。中国政府亦多次向国际社会公开表态必将竭尽全力实现“2030 年前碳达峰、2060 年前碳中和”的庄严承诺[2,3]。因此，准确预测中国能源需求与碳排放量，探究不同情景下中国碳排放的达峰时间和达峰峰值，对于政府制定节能减排政策，实现双碳目标，提供了理论依据与数据支持，具有十分重要的理论与现实意义。

为有效预测能源需求与碳排放，国内外学者进行了大量有益的探索。早期，多聚焦于采用单一的计量模型或者人工智能模型捕捉能源消费和碳排放时间序列自身的特征。例如，自回归移动平均模型(auto-regressive moving average model，ARIMA)[4] 、基于可拓展的随机性的环境影响评估模型- (stochastic impacts by regression on population, affluence, and technology，STIRPAT) [5,6]、灰色模型[7]、贝叶斯模型平均(bayes model averaging，BMA) [8]和神经网络模型[9]等。由于能源消耗与碳排放受经济、技术、政策、气候和社会行为等多维度因素动态耦合影响，具有高度的复杂、非线性特征。单一预测模型基于整体数据尺度建模，受样本规模和适用条件等客观因素影响，难以全面有效的提取能源消耗变化趋势中不同尺度信息，预测结果往往不尽人意。因而，研究者逐渐转向组合优化预测方法，试图通过模型协同与数据融合提升预测性能。例如：张兵兵等[10]综合运用高斯回归(GPR)、支持向量机(SVM)和梯度提升(GB)等机器学习算法对中国 267 个地级市及以上的城市的碳达峰路径进行了分析。Xiong 等[11]采用了一种新的基于改进型鱼群迁移优化算法的数值矩匹配技术(MFMOA-NMM)来预测建筑物能耗。Feng 等[12]提出了一种基于长短期记忆（LSTM）和 Transformer 模型构建的电动汽车能耗预测框架。李媛等[13]构建了基于 InVEST-Ridge Regression-PLUS 模型的混合优化分析框架，预测了云贵高原不同土地利用路径下区域碳储量的变化趋势。组合优化方法在一定程度上克服了单一模型的缺陷，但仍未解决整体数据尺度建模无法有效提取原始信息中多尺度数据特征的问题，不能精确刻画包含不同尺度低频序列和高频序列成分各自的演化规律。在这样的背景下，基于“分解-集成”策略的预测方法日益受到重视 [14,15]。“分解-集成”预测方法将原始数据序列分解为若干个不同尺度子序列，针对不同尺度数据序列的特征选择与之适配的异质预测模型，通过相加集成求取能源消费预测值。该范式不仅将原本复杂的预测问题转化为更简单的子序列预测问题，有效降低了原问题的复杂度和非线性，更为重要的是能够根据不同尺度数据特征确定适配性高的预测模型，从而达到提升预测性能的目的。分解策略主要包括：经验模态分解（empirical mode decomposition，EMD）[16,17]、变分模态分解（variational mode decomposition，VMD）[18,19]和小波分解（wavelet transform，WT）[20,21]等。分解的层次通常为单层分解和两层分解，相较于单层分解，两层分解通过二次分解进一步降低了非趋势项的复杂度，增强了对能源需求演化细节的捕捉能力，进而提升了预测精度[22]。然而，以上分解方法也具有一定的局限性，例如，小波分解具有良好的时频局部化能力，但是其分解效果在很大程度上依赖于小波基函数的选择，可能导致在分析非线性、非平稳的能源消费数据序列时产生信息泄露，无法完全自适应地捕捉其内在的复杂波动模式。变分模态分解通过变分框架有效克服了模态混叠问题，具有更强的噪声鲁棒性，但是该方法需要预先设定分解模态个数 K，而 K 值的确定是一个难题。相比之下，经验模态分解方法作为一种完全由数据驱动的自适

应分解技术，对复杂信号内在结构的自适应提取能力强，能够根据原始数据序列自身的局部时间尺度特征，将其分解为一系列本征模态函数。鉴于此，本文提出一种两层“分解-集成”策略下融合深度学习神经网络的预测模型，通过趋势分解和经验模态分解从原始能源消费数据序列中提取出低频趋势项和高频非趋势项，针对不同尺度分量所表现出的独特频域特征，匹配与之适应的计量经济学模型和深度学习模型进行预测，以实现对各类成分的精准拟合。该策略充分融合了信号分解方法在特征提取方面的优势，同时结合了深度学习模型在高维非线性数据建模上的强大能力，从而有效降低了原始数据序列的复杂性与动态性，不仅显著提升了整体序列的预测精准度与稳健性，更增强了对数据内在模式与演化规律的揭示能力。

本文旨在为我国双碳目标如期实现提供科学依据与政策靶点，主要的边际贡献如下：①提出了一种两层“分解-集成”策略下融合深度学习神经网络的预测方法，该方法结合计量经济学模型的可解释性与深度学习数据驱动模型强大能力，深入研究了多尺度信息中关键因素对能源消费与碳排放影响的内在机理。②通过两层分解提取能源消费数据序列中不同尺度的细节成分，利用 STIRPAT 模型揭示社会经济主导因素对能源消费的长期影响规律，并从能源消费原始数据序列中分离出低频趋势项和高频非趋势项，采用 EMD 模型对高频非趋势分成实施进一步分解，提取出若干多尺度数据子序列。③采用灰狼优化算法（GWO）对 LSTM 模型的超参数进行优化，并将其应用于高频非趋势项的 IMF 与残差项子序列的预测。④在基准情景基础上，设计 6 种单因素差异化发展情景和 4 种多因素耦合发展情景，系统推演了中国 2024～2035 年在不同情景下的能源消费量、碳达峰时间及峰值，以期为多路径政策制定提供量化依据。

1 材料与方法

1.1 数据来源

本研究涉及到的经济、人口和能源相关数据均来源于《中国统计年鉴-2024》。情景设定综合考虑了《中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要》《“十四五”现代能源体系规划》《2030 年前碳达峰行动方案》《国家人口发展规划（2016-2030 年）》等相关政策文件的数据进行相关情景规划。

1.2 研究方法

1.2.1 STIRPAT 扩展模型

STIRPAT 扩展模型是 IPAT 模型的改进形式，该模型综合考虑了人口、社会财富和技术等多维因素对环境压力的影响[23]，有效刻画了社会发展与环境压力之间的相互关系。公式可表示为：

$$I = a \times P^b \times A^c \times T^d \times e \tag{1}$$

式中，I、P、A和T分别表示环境、人口、经济和技术；a为常数项；b、c和d分别表示弹性系数；e表示随机误差项。对式(1)两边取对数，可以得到：

$$\ln I = \ln a + b \ln P + c \ln A + d \ln T + \ln e \tag{2}$$

式中， I表示环境压力，鉴于能源消费产生的碳排放是环境压力的主要来源，采用能源消费规模表征环境压力。在解释变量的选取上，综合现有研究的共性指标[24~29]，考虑到第二产业对碳基能源的高度依赖，以及对碳排放显著的负面影响，将第二产业产值纳入其中。另将社会财富水平（A）解构为人均 GDP 与城镇化率；技术水平（T）表示能源的有效利用程度，可用能源效率和非化石能源占比来进行解释。综上所述，选择人口规模、人均 GDP、第二产业产值、城镇化率、能源效率以及非化石能源占比作为 6 个关键影响因素，构建 STIRPAT 扩展模型，如式 (3) 所示。

$$\ln I = \ln a + \beta_1 \ln P + \beta_2 \ln A + \beta_3 \ln \mathrm{EE} + \beta_4 \ln \mathrm{IS} + \beta_5 \ln \mathrm{PU} + \beta_6 \ln \mathrm{ES} + \ln e \tag{3}$$

式中，I为能源消耗量（以标准煤计），单位为万 t；a为系数；P为人口总数，单位为万人；A为人均 GDP，单位为万元·人$^{-1}$；EE为能源效率，单位为%；IS为第二产业产值，单位为亿元；PU为城镇化率，单位为%；

ES为非化石能源占比，单位为%；β_1、β_2、β_3 、β_4、β_5和β_6分别P、A、EE、IS、PU和ES系数；e为模型随机干扰项。

考虑到 STIRPAT 扩展模型中的影响因素可能存在多重共线性，会对预测结果产生干扰，因此采用岭回归方法消除模型中自变量间的多重共线性影响[30]。针对最小二乘法在共线性数据上估计不稳定的问题，岭回归通过施加惩罚项，以牺牲部分无偏性为代价，获得回归系数更高的稳定性和实用性。岭回归中添加了一个正则化项，表示为式(4)。

$$L(\theta) = \sum_{i=1}^{n}(y_i - \sum_{j=1}^{m}\theta_j x_{ij})^2 + \lambda\sum_{j=1}^{m}\theta_j^2 \tag{4}$$

式中，n为序列中样本数据的数量，m为影响因素的数量，y_i为第i个样本数据的预测值，x_{ij}为第i个样本数据的第j个特征值，θ_j为第j个特征的权重，λ为正则化参数用以控制正则化项的强度。

1.2.2 经验模态分解

经验模态分解 EMD 一种信号分解算法，将原始时间序列分解成不同尺度的频域成分，一般为若干个内涵模态分量(intrinsic mode functions, IMF)[31,32]。在整个时间范围内，极值点的个数和过零点的个数必须相等或相差最多不超过一个。同时，在时间范围内的任意时刻，极值包络（由极大值构成的上包络线和由极小值构成的下包络线）在时间坐标轴附近呈现出局部镜像对称的特性[33]。EMD 通过迭代提取这些 IMF，并最终留下一个残差项，具体计算步骤如下。

步骤 1：找出原始信号$s(t)$的所有极大值和极小值。

步骤 2：进行 3 次样条插值，拟合极大值和极小值构成的上下包络线。

步骤 3：求解上下包络线的平均包络线$m(t)$。

步骤 4：计算$h(t) = s(t) - m(t)$。若$h(t)$同时满足 IMF 的上述两个要求，则$h(t)$为一个 IMF 分量，记为IMF$i(t)$；否则用$h(t)$替换$s(t)$。

步骤 5：重复步骤（1）-（4），直到$h(t)$小于设定值或为单调时间序列，停止计算，这个时刻的$h(t)$即为残差项res(t)。原始信号$s(t)$通过 EMD 分解成n个 IMF 和一个残差项res(t)，$s(t) = \sum_{i=1}^{n}\text{IMF}i(t) + \text{res}(t)$

1.2.3 GWO-LSTM 优化算法

经典 LSTM 模型超参数选择高度依赖人工经验，并且需要多次实验才能获取。因此，采用 GWO 优化算法对 LSTM 模型的隐含层神经元数、学习率等超参数进行自动寻优，以改善其预测性能[34,35]。

（1） GWO 优化算法　灰狼优化算法（grey wolf optimization，GWO）是 Mirjalili 等受灰狼种群捕猎行为启发而提出的一种智能优化算法[36]，灰狼在族群中分为α、β、δ和ω这 4 个等级，且优先级逐级下降。其中α为适应度最好的解，β和δ分别为第二和第三佳解决方案，ω为剩下的候选解。

灰狼的狩猎行为可分为包围、追捕以及发起攻击这 3 个主要环节[37~40]。

首先，狼群队列实施跟踪与包围过程的公式如式(5)～(8)所示。

$$D = \left|C \times X_p(t) - X(t)\right| \tag{5}$$

$$X(t+1) = X_p(t) - A \times D \tag{6}$$

$$A = 2 \times a \times r_1 - a \tag{7}$$

$$C = 2 \times r_2 \tag{8}$$

式中，D表示狼个体与猎物间的距离，t表示迭代系数，$X_p(t)$表示猎物的位置，$X(t)$表示狼个体的位置，系数A和C用于调节随机权重， r_1和r_2取[0,1]之间的随机数。收敛因子 a作为关键控制参数，在算法迭代过程中由 2 逐渐线性减小为 0，从而引导搜索从探索转向利用。

其次，在确定搜索方向后，狼群开始进入狩猎（优化）阶段。算法假定α、β和δ狼（即当前种群中适应度最好的 3 个解）对社会等级较低的ω狼起到引导作用。由于猎物的确切位置（全局最优解）未知，算法通

过α、β和δ的位置来共同估计猎物的可能区域。在每次迭代中，保留这 3 个最优个体，并根据它们计算出的位置信息，更新整个狼群的位置，完成对最优区域的包围和逼近，如式(9)～(15)所示。

$$D_\alpha = |C_1 \times X_\alpha - X| \tag{9}$$

$$D_\beta = |C_2 \times X_\beta - X| \tag{10}$$

$$D_\delta = |C_3 \times X_\delta - X| \tag{11}$$

$$X_1 = |X_\alpha - A_1 \times D_\alpha| \tag{12}$$

$$X_2 = |X_\beta - A_2 \times D_\beta| \tag{13}$$

$$X_3 = |X_\delta - A_3 \times D_\delta| \tag{14}$$

$$X(t+1) = \frac{X_1+X_2+X_3}{3} \tag{15}$$

式中，D_α、D_β和D_δ分别表示α、β和δ狼个体与其他狼个体之间的距离，C_1、C_2和C_3表示随机数，X_α、X_β和X_δ分别表示α、β和δ狼个体的当前位置，X表示当前灰狼个体的位置，X_1、X_2和X_3分别表示ω狼向α、β和δ狼移动的距离。

最后，在攻击猎物阶段，收敛因子a从 2 线性递减至 0。由于$A \in [-\alpha, \alpha]$,随着a的减小，$|A|$的取值范围也逐渐收缩。此机制实现了算法从全局探索到局部开发的过渡：当$|A| > 1$时，狼群侧重分散搜索，寻找全局最优；当$|A| < 1$时，狼群向猎物位置收敛（发起攻击），陷入局部最优。

（2）GWO 增强 LSTM 模型实现步骤

步骤 1：确定待优化的超参数向量及其上下边界，并确定灰狼算法的最大迭代次数。

步骤 2：初始化灰狼种群参数。随机生成 N 个灰狼个体，每个灰狼位置是一个多维向量，可解码为 LSTM 模型的一组待优化超参数，确保每个维度在给定的上下边界内。

步骤 3：生成系数向量A、C和收敛因子a。将 LSTM 模型的误差 RMSE 定义为灰狼算法的适应度值。

步骤 4：解码超参数并构建 LSTM 模型，在训练集上对构建的 LSTM 模型进行有限轮次的训练。采用训练完毕的 LSTM 模型对测试集数据进行预测并计算 RMSE。将 RMSE 值赋予当前灰狼，作为其适应度值。

步骤 5: 确定当前种群中适应度最好的三只狼，分别命名为α、β和δ狼,根据式（9）～（15）更新所有狼的位置。

步骤 6：重复步骤 3 到步骤 5，如果达到最大迭代次数则终止迭代。

步骤 7：输出最终α 狼的位置向量，即为 GWO 算法寻找到的最优超参数组合。

步骤 8：最终模型评估。

1.2.4 融合深度学习的两层“分解-集成”预测模型 TD-EMD-GWO-LSTM

本文所提出的基于两层“分解-集成”策略下融合深度学习的能源消费预测模型 TD-EMD-GWO-LSTM 算法流程如图 1 所示。

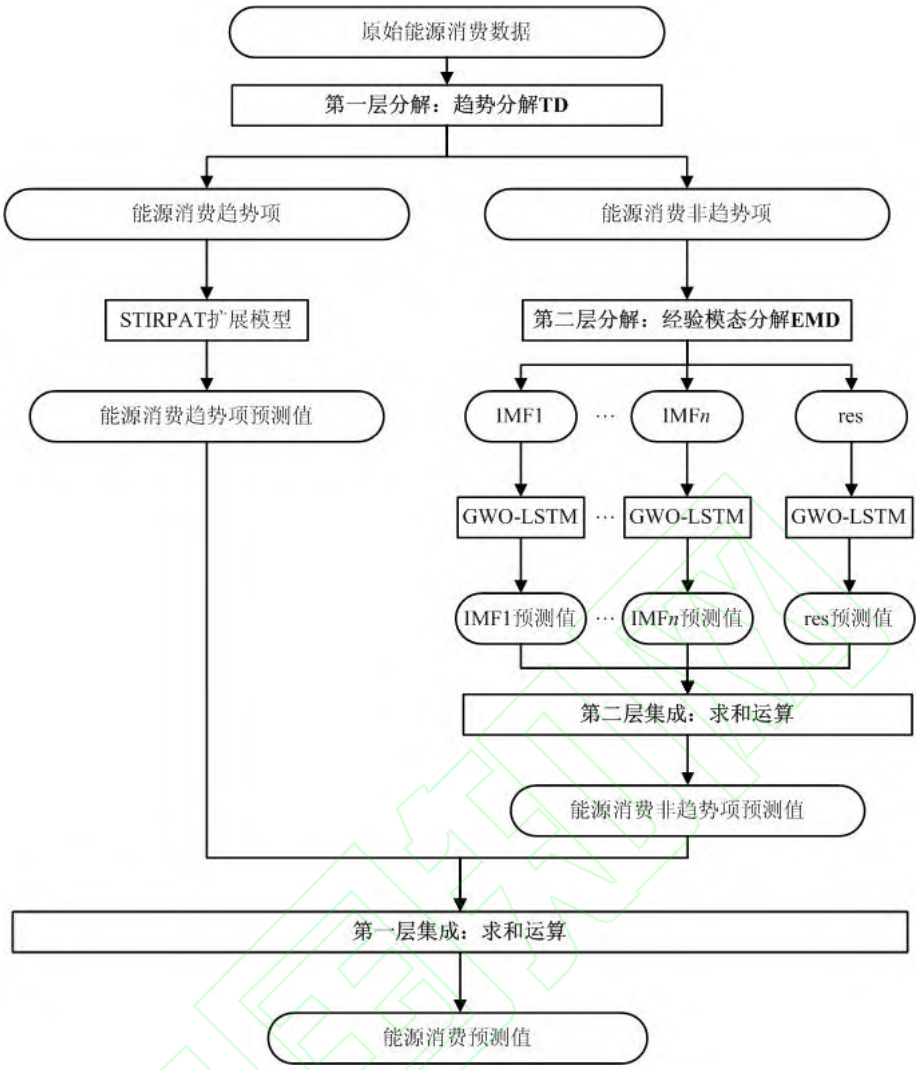

图 1 融合深度学习的两层分解-集成预测流程

Fig.1 Flowchart of a two-layer decomposition-integration prediction process integrated with deep learning

步骤 1：采用 STIRPAT 扩展模型实施趋势分解。提取能源消费数据序列中受经济和技术发展水平等主导因素影响的趋势项，分离出随机性程度较高的非趋势项。考虑到 STIRPAT 扩展模型的解释变量（人口、财富和技术水平）能反映相关数据信息的长期、稳定的发展趋势，可以刻画由系统性、结构性因素，如人口变化、经济增长和技术进步等导致的长期稳定的变化趋势。本文选择 STIRPAT 扩展模型对能源消费数据序列进行趋势分解，用以识别影响能源消费的长期驱动因素。STIRPAT 回归中，拟合值代表了由长期驱动因素解释的趋势项；残差代表了未被该模型解释的非趋势项，即短期波动和其他随机因素等。

步骤 2：采用 EMD 模型对非趋势项实施第二层分解。鉴于分离出的数据序列非趋势项动态性和非线性程度较强，使用具有快速自动分解功能的 EMD 模型将非趋势项进一步分解为不同尺度的若干个 IMF 项和一个 res 残差项。其中，高频模态分量反映了能源消费在短时间尺度上的瞬时扰动效应，例如气温骤变引起的空调负荷变化、大型工矿企业生产调度带来的能源消耗脉冲性波动等；次高频模态分量反映了能源消费在中等时间尺度上的周期性波动效应，例如季节性天气变化所导致的能耗起伏、工业生产节奏调整带来的能源消费量变化等；残差项 res 通常为低频趋势项，反映了持续数月的缓慢变化，可能源于跨季节的能源替代、小周期经济波动引发的能源消耗演变等。通过 EMD 分解，进一步明确了能源消费在不同时间尺度上的波动特征，降低了原始预测问题的复杂度。

步骤 3：使用 GWO 优化的 LSTM 模型对非趋势项经由二次分解获得的各个子序列进行预测。LSTM 的非线性数据序列建模能力强，能够自适应地学习并记忆时间序列中的长期依赖关系，非常适合刻画非趋势

项中可能存在的复杂时序动态。但 LSTM 的性能高度依赖于超参数的选择。因此，利用 GWO 算法对 LSTM 的超参数进行自动寻优，有效避免了模型陷入局部最优，提升了模型的收敛速度与预测精度。非趋势序列的预测结果通过将其子序列的预测值相加集成来获得。

步骤 4：对能源消费趋势项和非趋势项的预测值进行相加集成，求出最终的能源消费预测值。

1.2.5 碳排放测算方法

碳达峰是指化石能源消费产生的二氧化碳总量在一定时期内达到峰值，之后进入平台整理，然后逐渐下降的过程。因此，假设化石能源消耗过程中碳完全转化为二氧化碳，根据《2006 IPCC National Greenhouse Gas Inventories》的二氧化碳排放测算的 IPCC 系数法，如式（16）所示，测算我国能源消费产生的二氧化碳排放量。

$$C = \sum_{i=1}^{n} E \times \rho_i \times \varepsilon_i \times \frac{44}{12} \tag{16}$$

式中，C表示二氧化碳排放总量；E表示能源消费总量；i表示第i种能源；n表示能源种数；ρ_i表示第i种能源占能源消费总量之比；ε_i表示第i种能源的碳排放系数。不同种类能源的碳排放系数如表 1 所示。$\frac{44}{12}$表示能源中的碳转化二氧化碳的质量系数。

表 1 不同种类能源碳排放系数

Table 1 Carbon emissions coefficients of different energy

名称	煤炭	石油	天然气	非化石能源
排放系数	0.748	0.583	0.444	0

1.2.6 模型性能评价指标

为评估模型预测性能，选取平均绝对值百分比误差 MAPE 和均方根误差 RMSE 作为评价指标[41]，定义如式(17)和式(18)所示。

$$\mathrm{MAPE} = \frac{1}{n}\sum_{k=1}^{n}\left|\frac{Y_K - \hat{Y}_k}{Y_K}\right| \tag{17}$$

$$\mathrm{RMSE} = \sqrt{\frac{\sum_{k=1}^{n}(Y_K - \hat{Y}_k)^2}{n}} \tag{18}$$

式中，Y_k和$\hat{Y}_k$分别表示能源消费实际值和预测值；n为测试样本数。

1.3 情景设定

参考《中华人民共和国国民经济和社会发展第十四个五年规划和 2035 年远景目标纲要》及《2030 年前碳达峰行动方案》等重要政策文件，选取能源效率、能源结构（非化石能源占比）、经济增长（人均 GDP 增长）、人口规模、城镇化率以及第二产业产值作为能源消费的关键影响因素，设定了基准情景（表 2 与表 3）和情景 1 至情景 6，分析了上述影响因素在不同变化速率下对能源消费量及其碳排放的影响。

表 2 基准情景下各变量年增长率/%

Table 2 Annual growth rates of variables in the baseline scenario/**%**

年份	能源效率	能源结构	人均 GDP	人口	第二产业比例	城镇化率
2024	−3.5	5.704	4.97	0.1	−4	0.76
2025	−3.5	5.704	4.97	0.1	−4	0.76

2026	−2	4.5635	4.72	0.08	−3	0.72
2027	−2	4.5635	4.72	0.08	−3	0.72
2028	−2	4.5635	4.72	0.08	−3	0.72
2029	−2	4.5635	4.42	0.08	−3	0.72
2030	−2	4.5635	4.42	0.08	−3	0.72
2031	−1.5	3.7138	4.52	−0.02	−2	0.69
2032	−1.5	3.7138	4.32	−0.02	−2	0.69
2033	−1.5	3.7138	4.32	−0.02	−2	0.69
2034	−1.5	3.7138	4.32	−0.02	−2	0.69
2035	−1.5	3.7138	4.32	−0.02	−2	0.69

表 3 化石能源结构占比/%

Table 3 Proportion of fossil energy in the energy structure /%

年份	煤炭	石油	天然气	一次电力及其他能源
2025	53	18.3	8.8	20
2030	46	18.3	10.8	25
2035	36.6	18.3	15	30

1.3.1 基准情景设定

（1）能源效率　提升能源效率意味着以更少的能源投入获得同等的经济产出，这也是通过能效改进降低能源消费与碳排放的基本依据。《2030 年前碳达峰行动方案》提出，到 2030 年单位国内生产总值二氧化碳排放量要比 2020 年下降 18%。考虑到能源效率提升存在边际效应递减的规律，基准情景下设定 2024～2025 年、2026～2030 年和 2031~2035 年这 3 个阶段的能源效率年均增长率分别为−3.5%、−2%和−1.5%。

（2）能源结构　能源结构是影响碳排放总量和碳达峰时间的关键因素，也是推动二氧化碳减排的重要路径。绿色低碳的能源结构可从源头上降低单位能耗的碳排放强度。《“十四五”现代能源体系规划》明确提出，非化石能源消费占比将从 2025 年的 20%提高至 2030 年的 25%。据此，基准情景下设定 2024~2025 年、2026~2030 年和 2031~2035 年期间非化石能源占比的年均增长率分别为 5.704%、4.5635%和 3.7138%（2025 年、2030 年和 2035 年的非化石能源占比分别为 20%、25%和 30%）。

（3）人口规模　人口规模是影响碳排放的重要因素。受育龄妇女数量减少、年轻群体婚育观念转变以及生育养育成本上升等多重因素影响，我国人口增速将进入长期低迷阶段。《国家人口发展规划（2016–2030 年）》指出，中国人口将在 2030 年前后达到峰值。因此，基准情景下设定 2024~2025 年、2026~2030 年和 2031~2035 年期间的人口年均增长率分别为 0.1%、0.08%和−0.02%。

（4）GDP 增速　根据我国“十四五”规划目标，“十四五”期间 GDP 年均增速需达到 5.6%，并力争在 2035 年人均国内生产总值迈入中等发达国家行列。为此，设定 2024~2025 年 GDP 年均增长 5%，2026~2028 年为 4.8%，2029~2031 年为 4.5%，2032~2035 年为 4.3%，以基本实现上述目标。人均 GDP 通过 GDP 与人口总量之比计算得出，基准情景下相应期间的年均增长率分别为 4.97%、4.72%、4.42%、4.52%和 4.32%。

（5）第二产业产值　第二产业规模对碳排放具有显著影响。“十四五”规划提出，到期末第二产业比重预计降至 35.5%。《中共中央关于制定国民经济和社会发展第十五个五年规划的建议》进一步强调，“十五五”期间将继续以“建设现代化产业体系，巩固壮大实体经济根基”为核心战略，产业结构优化进程有望提速。考虑到“十五五”至“十六五”期间服务业将进一步发展，第二产业比重将持续缓步下降，基准情景下设定 2024~2025 年、2026~2030 年和 2031~2035 年第二产业占比的年均变化率为−4%、−3%和−2%。第二产业产值由 GDP 与第二产业比例相乘计算得出。

（6）城镇化率　近 3a 我国城镇化率年均提高约 0.76%。根据中国科学院农村发展研究所预测，到 2035 年

中国城镇化率将达 72%左右。基于此，基准情景下设定 2024~2025 年、2026~2030 年和 2031~2035 年期间城镇化率年均增速分别为 0.75%、0.72%和 0.69%。

1.3.2 情景设定

在基准情景基础上，将情景 1 至情景 6 中各因素的年均增长率调整为 3 种差异化水平（表 4），探讨其对能源消费与碳排放的影响机制与作用强度。

表 4 不同情景下各变量变化速率/%

Table 4 Change rate of variables under different scenarios /%

驱动因素	子情景	2024~2025 年	2026~2028 年	2029~2030 年	2031 年	2032~2035 年
情景 1（能源效率）	1.1	−3.75	−2.25	−2.25	−1.75	−1.75
	1.2	−4.25	−2.75	−2.75	−2.25	−2.25
	1.3	−4.75	−3.25	−3.25	−2.75	−2.75
情景 2（能源结构）	2.1	5.8181	4.6548	4.6548	3.7881	3.7881
	2.2	5.8751	4.7004	4.7004	3.8252	3.8252
	2.3	5.9892	4.7917	4.7917	3.8995	3.8995
情景 3（人均 GDP）	3.1	5.07	4.82	4.52	4.62	4.42
	3.2	5.17	4.92	4.62	4.72	4.52
	3.3	5.27	5.02	4.72	4.82	4.62
情景 4（人口规模）	4.1	0.09	0.07	0.07	−0.03	−0.03
	4.2	0.07	0.05	0.05	−0.05	−0.05
	4.3	0.04	0.02	0.02	−0.08	−0.08
情景 5（第二产业比例）	5.1	−4.25	−3.25	−3.25	−2.25	−2.25
	5.2	−4.5	−3.5	−3.5	−2.5	−2.5
	5.3	−4.75	−3.75	−3.75	−2.75	−2.75
情景 6（城镇化率）	6.1	0.81	0.77	0.77	0.74	0.74
	6.2	0.91	0.87	0.87	0.84	0.84
	6.3	1.01	0.97	0.97	0.94	0.94

（1）情景 1　鉴于节能技术的大力推广，能源效率将持续提升。将能源效率年增长率相对于基准情景分别设定为−0.25%、−0.75%和−1.25%，以此构建子情景 1.1、1.2 和 1.3。

（2）情景 2　为反映我国对绿色清洁能源利用的大力推广，能源结构优化将加速推进。将非化石能源占比年增长率相对于基准情景分别设定为 2%、3%和 5%，以此构建子情景 2.1、2.2 和 2.3。

（3）情景 3　基于不同的经济发展潜力，人均 GDP 年增长率将有所差异。将其相对于基准情景分别设定为 0.1%、0.2%和 0.3%，以此构建子情景 3.1、3.2 和 3.3。

（4）情景 4　考虑到未来人口将长期保持低速或负增长，人口年增长率将逐步放缓。将其相对于基准情景分别设定为−0.01%、−0.03%和−0.06%，以此构建子情景 4.1、4.2 和 4.3。

（5）情景 5　为体现产业结构调整的持续推进，第二产业比例年增长率将进一步下降。将其相对于基准情景分别设定为−0.25%、−0.5%和−0.75%，以此构建子情景 5.1、5.2 和 5.3。

（6）情景 6　在新型城镇化战略引导下，城镇化进程将呈现不同增速。将城镇化率年增长率相对于基准情景分别设定为 0.05%、0.15%和 0.25%，以此构建子情景 6.1、6.2 和 6.3。

2 结果与讨论

本部分围绕我国能源消费与二氧化碳排放开展实证研究，先检验所构建的融合深度学习的两层“分解-集成”模型的有效性，随后基于该模型对 2024～2035 年间多情景下我国能源消费与碳排放进行预测，最后结合预测结果展开深入分析，探讨支撑我国在 2030 年前实现碳达峰目标的能源结构优化与系统调整路径。

2.1 基于两层“分解-集成”策略的融合深度学习的预测模型性能验证

本研究将社会经济、人口与能源等相关数据划分为训练集（1990~2018 年）和测试集（2019~2023 年）两部分，分别用于构建预测模型与评估模型性能。所采用的融合深度学习的两层“分解-集成”预测模型，其实现流程主要包括以下 4 个步骤。

（1）采用 TD 对原始能源消费数据序列进行第一层分解。将其分解为趋势项X(trend)和非趋势项X(non-trend)。选取能源结构（非化石能源占比）、人均国内生产总值 GDP、第二产业产值、人口数量、能源效率和城镇化率作为 STIRPAT 模型自变量，对式（3）进行拟合。岭回归系数 k 在（0,1）区间内以步长 0.01 进行取值，经测试集评估并综合考虑岭迹图（图 2）系数的稳定性，最终确定 k=0.18。岭回归估计结果如表 5 所示，第一层分解结果展示于图 3。

表 5　Ridge 岭回归分析结果

Table 5 Ridge regression fitting results

项目	非标准化系数		标准化系数（Beta）	t	P	VIF 值
	回归系数（B）	标准误差				
常数	−9.57	1.832	—	−5.225	0.000**	—
ln$A$	0.111	0.007	0.226	15.346	0.000**	0.184
ln$P$	1.574	0.153	0.171	10.295	0.000**	0.235
lnIS	0.108	0.009	0.226	12.193	0.000**	0.291
lnPU	0.488	0.039	0.251	12.504	0.000**	0.343
lnEE	0.023	0.054	0.012	0.424	0.675	0.656
lnES	0.136	0.049	0.091	2.758	0.010*	0.917
R^2			0.968			
调整 R^2			0.961			
F			F (6,27)=137.019, P=0.000			

1）“—”表示无相关数据；*表示 P<0.05 ,**表示 P <0.01

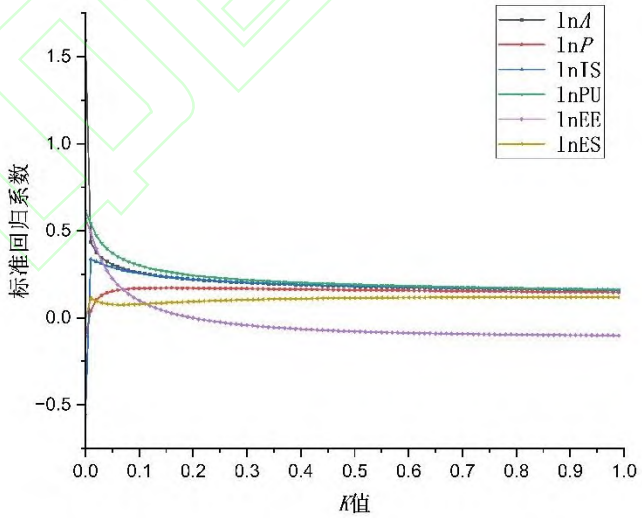

图 2　岭迹图

Fig. 2 Ridge trace plot

由表 5 可知，各解释变量的方差膨胀因子（VIF）均小于 5，说明模型中多重共线性问题得到了有效控制；回归模型的拟合优度（R^2）达到 0.968，反映出模型整体拟合效果良好；F 统计量在 1%水平上显著，进

一步支持了模型的整体显著性。综上所述，能源结构、人均国内生产总值、第二产业产值、人口数量、能源效率与城镇化率共同解释了能源消费 96.8%的变动，表明所选变量对能源消费变化具有较强的解释力。将表 5 中的岭回归系数代入式（3），得到如下岭回归方程，如式（19）所示。

$$\ln I = 1.574\ln P + 0.111\ln A + 0.023\ln \mathrm{EE} + 0.108\ln \mathrm{IS} + 0.488\ln \mathrm{PU} + 0.136\ln \mathrm{ES} - 0.957 \quad (19)$$

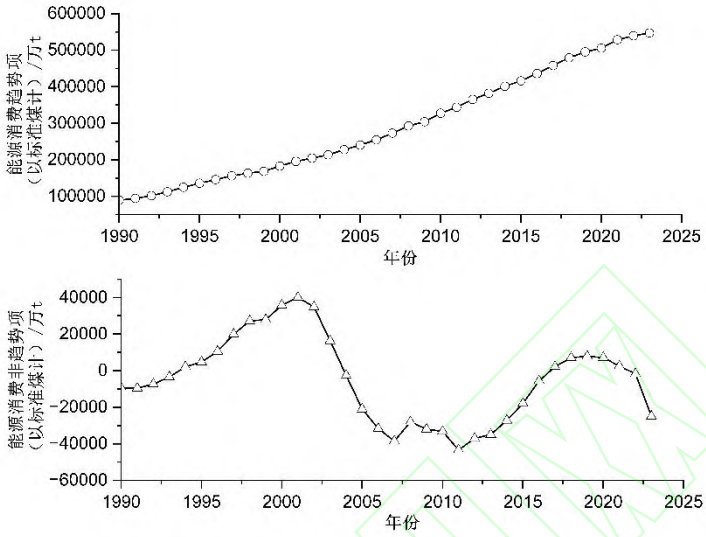

图 3 能源消费的 TD 分解结果

Fig. 3 TD results of energy consumption

（2）对非趋势项X(non-trend)实施第二层分解，进而提取出不同尺度的数据序列，包括 2 个本征模态函数 IMF1、IMF2 和一个残差项（res），如图 4 所示。

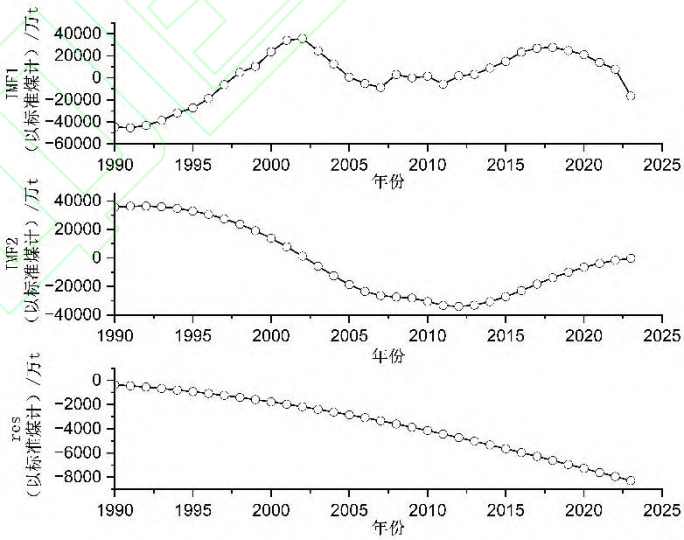

图 4 非趋势项的 EMD 分解结果

Fig. 4 EMD decomposition results of the non-trend components

（3）能源消费趋势项利用 STIRPAT 模型预测；非趋势项IMFi（子序列和res子序列）采用灰狼优化增强的

LSTM 模型预测，隐含层神经元数量与学习率下降周期由 GWO 优化算法自动寻优确定。LSTM 设置了 1 个 LSTM 隐藏层，输入层和输出层神经元数均为 1，学习率下降因子为 0.1。在构建三层 LSTM 网络时，输入层与输出层的神经元数均设定为 1，而隐含层神经元数的合理设置对模型性能具有关键影响。隐含层神经元数直接决定了模型对时序依赖关系的捕捉能力与模型复杂度：神经元数过少可能导致欠拟合，难以充分学习序列中的有效信息；神经元数过多则容易引发过拟合，降低模型泛化能力，同时增加计算负担。此外，学习率决定了 LSTM 的学习速度：学习率越大，参数更新步长越大，训练速度越快；但若学习率过大，可能导致训练过程无法收敛。因此，本文通过 GWO 算法对 LSTM 隐含层神经元数和学习率进行超参数寻优，以在模型表达能力与训练效率之间取得平衡。

（4）采用相加集成方法对上述各子序列预测值进行求和，求取能源消费的最终预测值。

2.2 模型预测效果分析

为检验本文所提出模型的预测性能，选取以下竞争模型作为对比：单一预测模型（STIRPAT 模型、LSTM 模型）、单层“分解-集成”方法（TD），以及基于经典 LSTM 的两层“分解-集成”方法（TD-EMD-LSTM）。基于上述四种预测模型在能源消费预测上的对比结果如表 6 所示，可得出如下结论。

表 6 不同模型的预测性能

Table 6 Prediction performance using different models

年份	相对误差/%				
	STIRPAT	LSTM	TD	TD-EMD-LSTM	TD-EMD-GWO-LSTM
2019	1.62	3.49	0.57	0.98	0.45
2020	1.43	4.44	1.58	0.70	0.72
2021	0.47	1.63	1.92	0.48	0.67
2022	0.32	1.00	2.30	0.74	0.71
2023	4.38	2.74	1.13	2.17	0.34
MAPE/%	1.64	2.66	1.50	1.01	0.58
RMSE/万 t	12237.1604	15016.9595	8591.21	6508.55	3112.86

（1）在预测精度方面，单一预测模型（STIRPAT 与 LSTM）、单层“分解-集成”模型（TD）、基于经典 LSTM 的两层“分解-集成”模型（TD-EMD-LSTM）以及基于 GWO 优化 LSTM 的两层“分解-集成”模型（TD-EMD-GWO-LSTM）的 MAPE 值依次为 1.64%、2.66%、1.50%、1.01%和 0.58%。结果显示，所有构建的模型均能较好刻画能源消费时序的演化规律，表现出较高的预测精度。其中，所提出的 TD-EMD-GWO-LSTM 方法预测误差最低，其 MAPE 较其他四种对比模型分别降低了 65%、78%、61%与 43%。

（2）与单一预测模型相比，采用“分解-集成”策略的模型均取得了更优的预测效果。该策略借助时序数据的分解策略提取原始序列中的多尺度特征，有效降低了预测问题的复杂性与非线性程度，从而提升了能源消费预测的整体性能。

（3）在“分解-集成”策略的预测模型中，两层分解模型预测性能优于单层分解模型，其中 TD-EMD-GWO-LSTM 模型表现最佳，TD-EMD-LSTM 模型次之。相比于单层分解，两层分解模型融合了趋势分解与经验模态分解的优点，将原始序列分解为更简单的子成分，并针对各子序列特点选用更适配的预测方法，从而更全面地捕捉数据在不同尺度下的演化规律，获得更优的预测效果。

因此，所提出的 TD-EMD-GWO-LSTM 模型能够有效识别能源消费趋势项与非趋势项的内在演化规律，在能源消费预测中具有良好的有效性和适用性。

2.3 能源消费量预测结果分析

（1）在基准情景下（图 5），能源消费量（以标准煤计）从 2023 年的 572000 万 t 增至 2030 年的约 646712

万 t，并在 2035 年进一步上升至约 688916 万 t。2023~2035 年的年均增速为 1.55%，较 2010~2023 年的 4.09%显著下降。分阶段看，“十四五”（2021~2025）期间年均增速为 2.98%，“十五五”（2026~2030）期间为 2.24%，“十六五”（2031~2035）期间降至 1.26%，表明能源消费增长明显放缓，反映出经济结构转型、节能减排与能效提升政策的积极效果。

（2）在情景 1 中，能源效率增长率相较于基准情景分别调低 0.25%、0.75%和 1.25%，2035 年能源消费量分别为 688447 万 t、687506 万 t 和 686562 万 t，年均增速介于 1.52%~1.54%。结果显示，能源效率提升对抑制能源消费具有明显作用。

（3）在情景 2 中，能源结构增长率较基准分别提高 2%、3%和 5%。2035 年能源消费量分别为 689830 万 t、690287 万 t 和 691202 万 t，年均增速介于 1.56%~1.58%。这表明非化石能源占比的提升主要推动能源系统“脱碳”，而非绝对降低能源消费总量，其核心目标是实现能源结构清洁化。

（4）在情景 3 中，人均 GDP 增长率较基准分别上调 0.1%、0.2%和 0.3%，2035 年能源消费量分别达到 689817 万 t、690665 万 t 和 691513 万 t，年均增速介于 1.56%~1.58%，说明经济增长对能源消费有拉动效应。

（5）在情景 4 中，人口增长率较基准分别下调 0.01%、0.0%3 和 0.06%，2035 年能源消费量分别为 687661 万 t、685159 万 t 和 681422 万 t，年均增速介于 1.46%~1.53%之间，反映出人口增长对能源消费呈正向影响，其放缓则产生抑制效果。

（6）在情景 5 中，第二产业产值增长率较基准分别降低 0.25%、0.5%和 0.75%，2035 年能源消费量分别为 686701 万 t、684487 万 t 和 682276 万 t，年均增速介于 1.47%~1.52%，表明第二产业规模下降对能源消费具有显著结构性抑制作用。

（7）在情景 6 中，城镇化率较基准分别提高 0.05%、0.15%和 0.25%，2035 年能源消费量分别为 690851 万 t、694737 万 t 和 698641 万 t，年均增速介于 1.57%~1.67%之间，说明城镇化进程持续推进对能源消费形成显著拉动。

综合所有预设情景的预测结果，2021~2035 年间中国能源消费总量仍将保持稳步增长（图 6）。基准情景显示，“十四五”、“十五五”和“十六五”期间年均增速逐步下降，分别为 2.98%、2.24%和 1.26%，情景 1 至情景 6 亦呈现一致的增速放缓趋势。随着碳达峰与碳中和行动的深入推进，能源结构持续优化以及可再生能源对煤炭的加速替代，能源绿色低碳转型措施已对能源消费增长形成有效抑制。

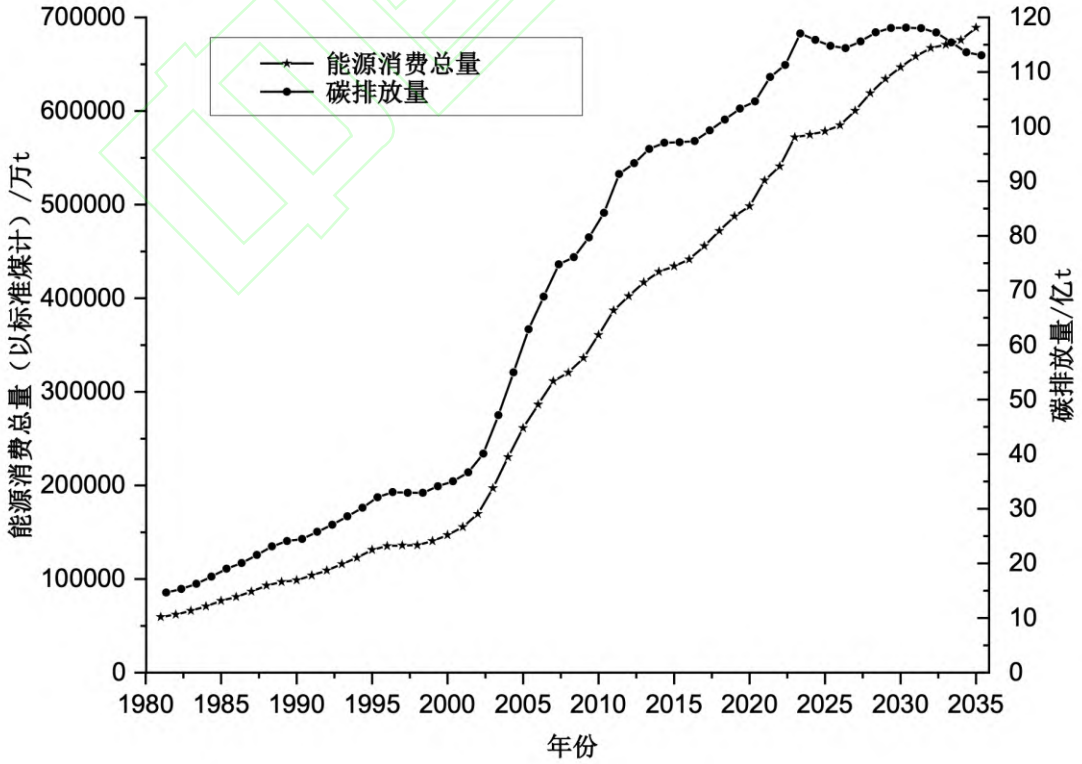

图 5 2024~2035 年基准情景下中国能源消费和碳排放量预测

Fig. 5 Prediction of China's energy consumption and carbon emission under the baseline scenario from 2024 to 2035

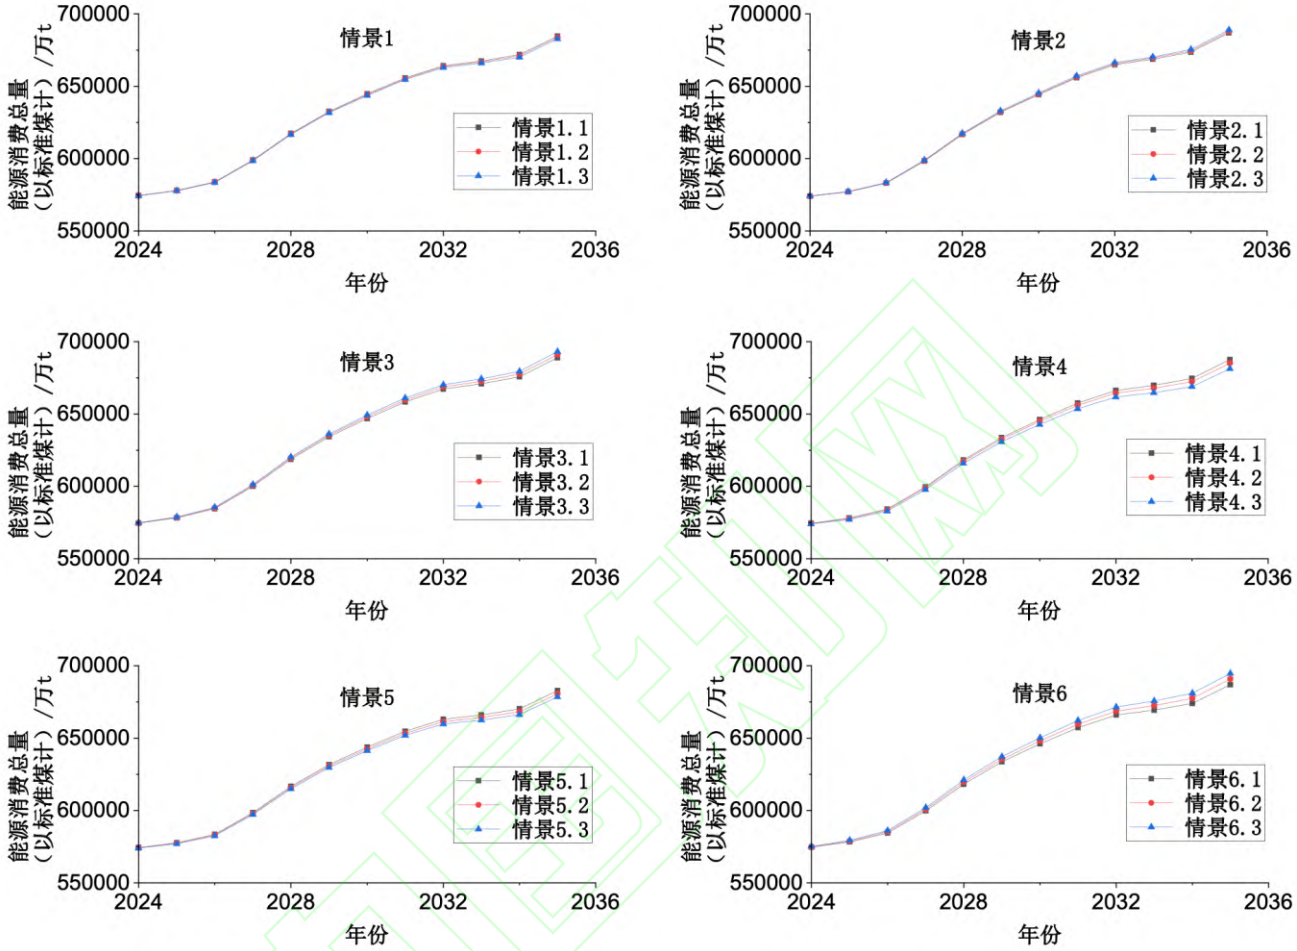

图 6 2024~2035 年中国能源消费预测

Fig. 6 China's energy consumption prediction results from 2024 to 2035

2.4 碳排放预测结果分析

运用情景分析法，在上述基准情景基础上分别针对情景 1 至情景 6（共 18 种子情景），预测我国碳达峰的时间和峰值（图 7 与表 7）。

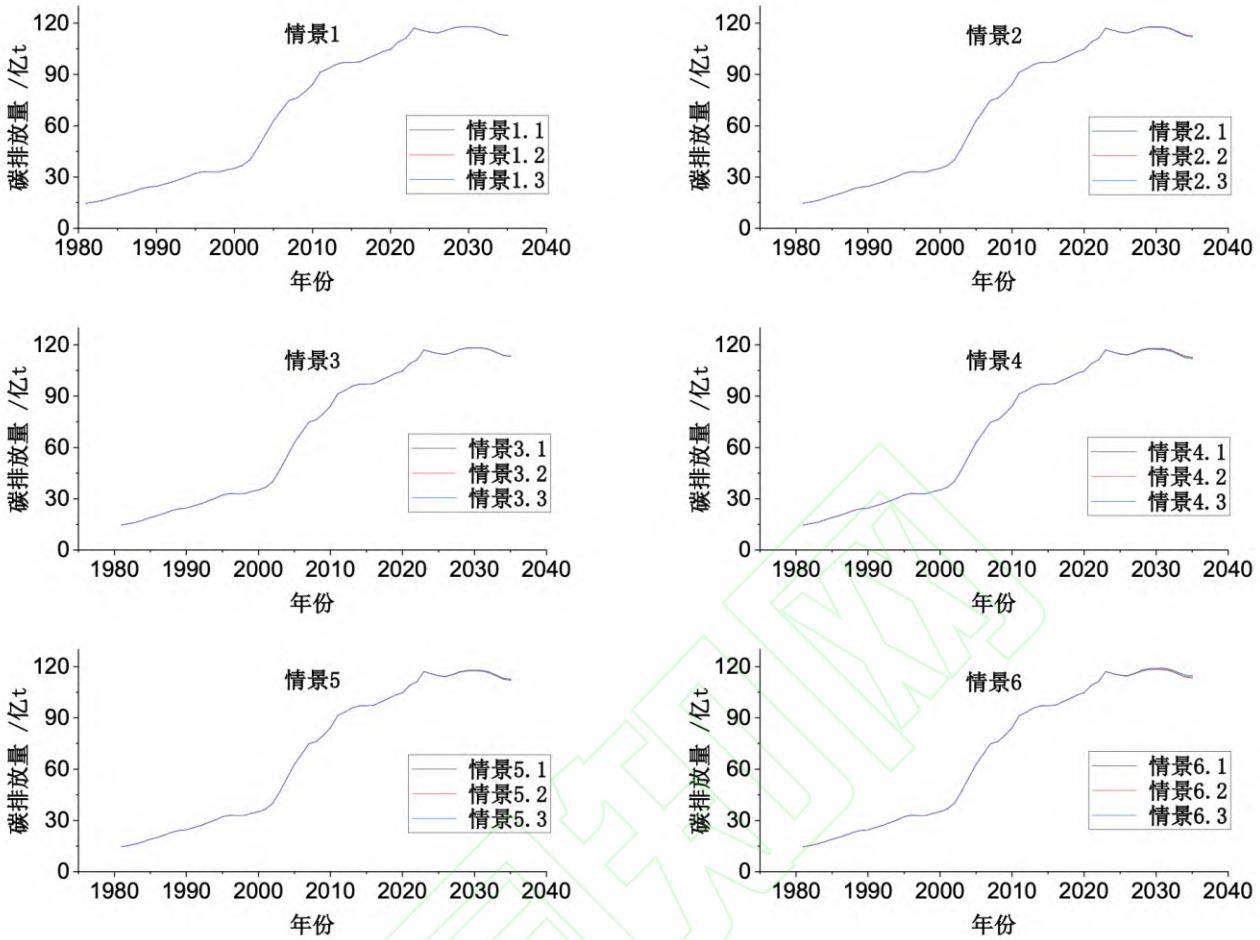

图 7 2024~2035 年中国碳排放量预测

Fig. 7 China's carbon emission prediction results from 2024 to 2035

表 7 不同情景下碳达峰时间和峰值

Table 7 Carbon peak time and peak value under different scenarios

驱动因素	子情景	二氧化碳排放年均增速/%			达峰峰值/亿 t	碳达峰年份
		2021～2025 年	2026~2030	2031~2035		
情景 1（能源效率）	1.1	1.85	0.57	−0.88	118.0662	2030
	1.2	1.85	0.56	−0.89	117.9728	2030
	1.3	1.85	0.54	−0.91	117.8789	2030
情景 2（能源结构）	2.1	1.85	0.55	−0.92	117.9226	2030
	2.2	1.85	0.53	−0.94	117.8282	2029
	2.3	1.84	0.51	−0.99	117.6771	2029
情景 3（人均 GDP）	3.1	1.86	0.58	−0.87	118.2057	2030
	3.2	1.87	0.59	−0.86	118.2894	2030
	3.3	1.87	0.60	−0.85	118.3731	2030
情景 4（人口规模）	4.1	1.85	0.56	−0.89	117.9887	2030
	4.2	1.84	0.53	−0.92	117.7409	2030

	4.3	1.82	0.48	−0.97	117.4138	2029
情景 5（第二产业比例）	5.1	1.85	0.55	−0.90	117.8923	2030
	5.2	1.83	0.52	−0.93	117.6729	2029
	5.3	1.82	0.49	−0.96	117.4830	2029
情景 6（城镇化率）	6.1	1.87	0.59	−0.85	118.3042	2030
	6.2	1.89	0.64	−0.81	118.6876	2030
	6.3	1.90	0.69	−0.76	119.1147	2031

（1）在基准情景下（图 5）　碳达峰时间为 2030 年，峰值达 118.1128 亿 t。2023~2035 年期间碳排放年均增速为–0.28%，较 2010~2023 年间的年均增速 2.96%显著回落。分阶段看，“十四五”（2021~2025）期间年均增速为 1.85%，“十五五”（2026~2030）期间为 0.57%，“十六五”（2031~2035）期间转为负增长，为–0.88%。

（2）在情景 1 中　随着能源效率提升幅度增大，碳达峰时间保持不变（均为 2030 年），但峰值逐步降低。情景 1.1、1.2 与 1.3 的峰值依次降至 118.0662 亿 t、117.9728 亿 t 和 117.8789 亿 t，表明能源效率提升对碳排放总量具有显著抑制效应。这一结果印证了提升能源效率是推动高质量达峰、控制排放总量的关键手段。

（3）在情景 2 中　能源结构优化进程加快使碳达峰时间提前至 2029 年，且峰值下降。情景 2.2 与 2.3 均于 2029 年达峰，峰值分别为 117.8282 亿 t 和 117.6771 亿 t；情景 2.1 达峰时间仍为 2030 年，峰值降至 117.9226 亿 t。这说明能源结构优化不仅能够抑制碳排放，还可促使达峰时间提前，是实现“早达峰、低峰值”目标最直接有效的核心策略之一。

（4）在情景 3 中　随着人均 GDP 增速提高，达峰时间不变而峰值上升。情景 3.1、3.2 与 3.3 的峰值分别为 118.2057 亿 t、118.2894 亿 t 和 118.3731 亿 t，说明人均 GDP 增长对碳排放仍具显著拉动作用。反映出传统经济增长模式与碳排放尚未脱钩，经济快速扩张会推高能源消费需求，不仅抬升达峰总量，也为后续碳中和路径带来更大减排压力与成本。

（5）在情景 4 中　人口增速放缓可降低碳达峰峰值，若人口持续负增长，达峰时间可提前至 2029 年。情景 4.1 与 4.2 达峰时间仍为 2030 年，峰值分别降至 117.9887 亿 t 和 117.7409 亿 t；情景 4.3 则提前至 2029 年达峰，峰值进一步降至 117.4138 亿 t。表明人口增长对碳排放具有拉动效应，其放缓或负增长将通过降低能源总需求直接抑制碳排放，凸显人口作为长期驱动因素的关键作用。

（6）在情景 5 中　第二产业比重下降至一定程度可使达峰时间提前并降低峰值。情景 5.1 达峰时间不变，峰值降至 117.8923 亿 t；情景 5.2 与 5.3 均提前至 2029 年达峰，峰值分别为 117.6729 亿 t 和 117.4830 亿 t。说明产业结构优化对碳达峰时间与排放总量均产生积极影响。不同情景间的差异进一步揭示，产业结构优化的力度与速度是决定达峰进程的关键变量，此类优化不仅是结构性减排的根本路径，也有助于经济摆脱高碳依赖、重塑增长模式。

（7）在情景 6 中　城镇化率提升到一定水平将推迟达峰时间并推高峰值。情景 6.1 与 6.2 的达峰时间不变，峰值分别升至 118.3042 亿 t 与 118.6876 亿 t；情景 6.3 在城镇化率增速达约 1%时，达峰时间推迟至 2031 年，峰值升至 119.1147 亿 t。这表明城镇化对碳排放具有显著拉动作用，并在一定程度上延缓达峰进程。城镇化进程的推进伴随大量市政、住房和交通基础设施投资与建设需求，这些设施在建设和运营过程中将产生大量碳排。农村人口大量转移到城市后，改变居民生活方式与用能结构，从而锁定高碳排路径。

（8）在基准情景基础上设定的 6 类情景共 18 种子情景　其中有 17 种子情景可在 2030 年前实现碳达峰，仅情景 6.3 推迟至 2031 年达峰。从“十四五”到“十六五”期间，二氧化碳排放年均增速逐步放缓，表明当前我国实施的减碳政策成效显著，符合低碳可持续发展战略的内在要求。预测结果表明：①能源效率、能源结构、人均 GDP、人口规模、第二产业产值与城镇化率均是实现碳减排的关键驱动因素；②上述因素对达峰时间与峰值的影响程度存在明显差异，其中能源结构与产业结构的影响最为突出。因此，加快推进能源结构优化，并着力推动产业结构调整、积极培育以服务业为核心的第三产业，将有助于提前碳达峰时间窗口并降低峰值；③城镇化进程对碳排放具有重要影响，若延续传统发展模式，将推高峰值并可能延迟达峰。因此，应推动城镇化发展模式由高消耗、高排放的“外延式扩张”向集约、智能、绿色的“内涵式发展”转型；

④能源效率提升意味着以更少能源投入获取更多经济产出，其与能源结构优化“双管齐下”可形成协同效应，共同构成推动碳排放快速下降的重要动力，是实现“双碳”目标的关键路径；⑤人口增长作为碳排放的重要影响因素，与经济社会发展深度耦合，既带来发展动力也伴随环境压力，未来应将重心转向提升人口素质、优化人口结构的高质量发展方向；⑥现阶段人均 GDP 增长仍拉动碳排放总量上升，符合环境库兹涅茨曲线的描述，表明我国尚处于工业化中后期阶段。随着经济发展水平进一步提高，人均 GDP 与碳排放有望逐步实现“脱钩”。

2.5 多因素耦合情景下碳排放预测结果分析

针对单一关键变量设定不同的年增长率，揭示了各因素独立影响碳达峰过程的内在机制及其作用强度。然而，社会经济系统具有复杂的动态性，各变量并非孤立演变，而是存在广泛的交互与协同。因此，为进一步揭示碳达峰路径，有必要将分析维度拓展到多因素耦合作用情景，以探究在多种驱动力共同作用下，碳达峰时间与峰值可能受到的综合影响。据此，借鉴 6 种关键变量年增长率不同的 3 种子情景构建了节能模式、高增长模式、绿色发展模式和低碳发展模式 4 种耦合情景（表 8）。

表 8 多因素耦合情景组合

Table 8 Multi-factor coupling scenario combinations

耦合情景	耦合模式下关键变量子情景设定						达峰峰值/亿 t	碳达峰年份
	能源效率	能源结构	人均 GDP	人口规模	第二产业产值	城镇化率		
节能模式	1.1	2.1	3.1	4.3	5.1	6.1	117.2455	2029
高增长模式	1.1	2.1	3.3	4.1	5.1	6.3	118.4955	2030
绿色发展模式	1.2	2.2	3.2	4.2	5.2	6.2	117.5239	2029
低碳发展模式	1.3	2.3	3.3	4.2	5.3	6.2	117.1035	2029

（1）节能模式　该模式追求经济的适度发展和节能减排的渐进式优化，各关键变量均保持低速增长态势。节能模式下经济增长保持平稳，人口数量增长缓慢，城镇化有序推进，产业结构与能源结构渐进优化，能源利用效率逐步提升。在此模式下，我国预计可在 2029 年实现碳达峰，达峰峰值下降为 117.2455 亿 t。

（2）高增长发展模式　该模式仍以追求社会经济的快速扩张为主。高增长模式下经济快速增长，人口持续扩张，城镇化率继续提速，即人均 GDP、人口、城镇化率 3 项指标均按最大增长速度设定；同时，产业结构、能源结构与能源效率均按照最低增速保持适度发展。在此模式下，我国在 2030 年实现碳达峰，碳达峰峰值增长至 118.4955 亿 t。

（3）绿色发展模式　该模式兼顾了经济增长与节能环保目标，社会经济与生态环境进入协调并进的“和谐”发展状态。人均 GDP、人口与城镇化率均按照中等发展速度，即子情景 2 设定。同时，优化产业结构与能源结构持续优化、能源效率稳步提升，环境保护与治理水平得到较快提升，即能源结构、产业结构、能源效率 3 项指标也按照中等发展速度即子情景 2 设定，此模式下我国碳达峰时间提前至 2029 年，峰值下降至 117.5239 亿 t。

（4）低碳发展模式　在绿色发展模式基础上，进一步强化经济目标与碳减排目标，将人均 GDP 增速提升至最高增速；相应的，将产业结构、能源结构与能源效率等关键变量均同步提升至最高增速。此模式下，我国经济发展进入高质量发展阶段，人口保持相对稳定、城镇化率增速较快，产业结构与能源结构优化加速，能源效率大幅提升，低碳技术创新不断涌现，环境保护与治理水平显著提升。此模式下我国碳达峰时间提前至 2029 年，达峰峰值下降至 117.1035 亿 t。

通过以上 4 种多变量耦合发展情景的对比分析可知，①在所有耦合情景下我国均可在 2030 年前实现碳达峰，说明在现行的政策框架和技术发展水平下，碳达峰目标的实现具有坚实可靠的基础。②在 4 种耦合情景下，高增长发展模式碳达峰峰值最大，接着依次是绿色发展模式、节能模式和低碳发展模式，这说明单纯追求经济增长会显著推高峰值，而强化结构调整与技术创新能有效的抵消经济增长导致的碳排，最终实现提前达峰、低峰值达峰。③“城镇化率高速推进”对碳达峰的负面影响可通过产业结构、能源结构和

能源效率的协同优化予以化解。这凸显了系统性与协同性政策的重要性，也进一步揭示了环境保护与治理是一项需要多维度统筹、整体推进的系统工程。④低碳发展情景实现了经济发展与碳排放的脱钩。

2.6 建议

鉴于我国正处于实现2030年碳达峰的冲刺阶段，为了确保如期达峰并减轻未来碳中和阶段的减碳压力，提出以下政策建议。

（1）2030 前确保如期达峰，低峰值达峰。鉴于产业结构和能源结构优化是碳达峰最关键的影响因素，为确保如期达峰，应深化结构调整，积极培育以服务业为核心的第三产业，大力发展数字经济、绿色经济相关产业，构建清洁低碳安全高效的能源体系。对于“高能耗”的行业，如交通、工业领域进一步提升能源利用效率。在保证城镇化有序推进的同时，大力推行绿色低碳城乡建设模式和生活方式，降低城镇化进程中的碳锁定效应。对“高增长模式”惯性较大的地区进行重点监督管理，引导其强化结构调整与能源利用效率的协同效应，力争低峰值达峰。

（2）2030 年后推动碳排稳步下降。碳达峰目标实现后，我国经济仍处于向“高质量发展”的战略转型关键期，工业化进程也尚待从中后期向后期转型，亟需推进系统性、结构性改革，推动经济增长方式从依赖能源资源投入转向依靠技术创新与消费升级。应制定具有针对性的减排路线图，加强节能减排领域的技术创新，推动建立以新能源为主的能源系统，促进工业行业的深度“脱碳”。确保经济向“高质量”发展阶段转型，倡导简约低碳生活方式，形成全社会共同参与的气候治理新格局。

3 结论

（1）提出了一种融合深度学习的两层“分解-集成”策略的预测框架，通过提取原始数据序列的多尺度数据特征，降低了原始预测问题的复杂度，提高了预测精度。构建了一种融合计量经济学模型与深度学习模型的集成预测方法。利用 STIRPAT 模型揭示社会经济主导因素对能源消费趋势性成分的长期影响规律；采用 GWO 优化的长短期记忆网络（LSTM）捕捉能源消费序列中的非趋势波动与长期依赖特征。最终，通过将两类模型的输出结果相加，得到能源消费的集成预测值。 实证结果验证了本文所提出的两层“分解-集成”策略通过两层分解，更加全面地提取了能源消费时间序列中不同尺度的细节成分，能够更精准的刻画原始数据的演化规律，将其应用于能源消费预测可行且有效。

（2）在基准情景的基础上，从社会经济技术发展及能源产业结构优化调整视角设定了 6 种关键变量独立作用情景，并分别进行了推演预测。结果表明：①我国能源消费总量在未来 10a 期间仍将继续保持增长，但增速显著放缓；②在所设定的六种关键变量独立作用情景(共 18 种子情景)下，绝大多数情景均实现了 2030 年前碳达峰目标，仅情景 6.3 中，当城镇化率达到 1%左右时，达峰时间推迟到 2031 年。③2024~2035 年期间，碳排放总量增速呈现逐渐下降直至负增长的态势；④能源结构优化和产业结构优化对碳达峰窗口时间和碳达峰峰值均产生显著的正面影响。

（3）在识别 6 种关键变量独立作用的基础上，构建了 4 种多变量耦合作用情景，分别为：节能模式、高增长模式、绿色发展模式和低碳发展模式，并分别进行了推演预测。结果表明：①所有耦合情景均能实现 2030 年碳达峰目标。这 4 种耦合情景发展重点各异，但均能如期达峰，验证了实现碳达峰目标的多路径可达性。这为处于不同发展阶段和具有不同资源禀赋的区域提供了差异化的达峰策略选择；②这 4 种耦合情景的达峰时序和达峰峰值差异性凸显了双碳目标的达成关键在于统筹发展与减排，需要依赖系统性治理和协同性政策才能动态优化；③“城镇化高速发展”对碳达峰产生的短期负面影响，完全可以通过优化产业结构和能源结构，提升能源效率来抵消；说明通过深层结构优化与技术渗透，能够实现碳排放与经济增长的强解耦；④低碳发展阶段实现了经济增长与环境治理的齐头并进，是“经济发展”与“环境污染”脱钩阶段。

（4）总体而言，本文所提出的融合深度学习的两层分解-集成模型在一定程度上能够有效预测中国能源消费。然而，本研究仍存在一些尚未完全解决的局限性，未来可能的研究挑战如下：首先，分解方法在能源消费预测中的物理意义仍需深入探究，这对于合理选择分解方法至关重要；其次，适当增加分解层次是否能取得更好的预测性能；此外，应将所提出的预测模型拓展至更多样的能源消费预测应用场景中，进一步验证

适用性和有效性。

参考文献：

[1] 邹才能,李士祥,熊波,等.新质生产力下“能源绿色转型”革命及意义——兼论“能源三角”理论认识[J].石油勘探与开发,2024,**51**(6):1395-1408.
Zou C N, Li S X, Xiong B, *et al*. Revolution and significance of “Green Energy Transition” in the context of new quality productive forces: A discussion on theoretical understanding of “Energy Triangle”. Petroleum Exploration and Development, 2024,**51**(6):1395-1408.

[2] 单葆国,姚力,张成龙,等.中国能源消费碳排放达峰情景预测：基于STIRPAT扩展模型[J].环境科学,2025,**46**(7):4052-4064.
Shan B G, Yao L, Zhang C L, *et al*. Carbon peak prediction of energy consumption in China: based on STIRPAT extended model[J]. Environmental Science, 2025,**46**(7):4052-4064.

[3] 陆海岳,齐娇娇,叶延磊,等.中国不同行政尺度下的碳收支时空变化特征[J].环境科学,2024,**45**(10):5601-5612.
Lu H Y，Qi J J, Ye Y L, *et al*. Characteristics of spatiotemporal changes in China's carbon budget at different administrative scales[J]. Environmental Science, 2024,**45**(10):5601-5612.

[4] 陈浩,胡静茹,王寿兵,等. 中国钢铁行业 CO2 排放特征和减排路径研究-基于ARIMA-LEAP 模型[J].中国环境科学, 2024,**44**(6):3531-3543.
Chen H, Hu J R, Wang S B, *et al*. Research on carbon dioxide emission characteristics and emission reduction path of China's iron and steel industry based on ARIMA-LEAP model[J]. China Environmental Science, 2024,**44**(6):3531-3543.

[5] 梁力军,马梦泽,冯江林.基于STIRPAT模型的山地城市碳达峰预测与实证：以重庆市数据为例[J].环境科学,2026，**47**(4),doi：10.13227/j.hjkx.202503185.
Liang L J, Ma M Z, Feng J L. Prediction and demonstration of carbon peak in mountain cities based on the STIRPAT model: A case study of Chongqing data[J]. Environmental Science,2026, **47**(4), doi: 10.13227/j.hjkx.202503185.

[6] 李华金,黄嘉信,狄亚轩.长江中游城市群碳解锁空间关联网络及影响因素[J].生态学报,2025,**45**(14):7065-7079.
Li H J, Huang J X, Di Y X. Spatial association network of carbon unlocking and influencing factors in the urban agglomeration in the middle reaches of the Yangtze River[J]. Acta Ecologica Sinica,2025,**45**(14):7065-7079.

[7] Ding S, Hu J, Lin Q. Accurate forecasts and comparative analysis of Chinese CO2 emissions using a superior time-delay grey model[J]. Energy Economics, 2023, **126**, doi:10.1016/j.eneco.2023.107013.

[8] Zhang M, Zhou S, Wang Q, *et al*. Will the carbon neutrality target impact China's energy security? A dynamic Bayesian network model[J]. Energy Economics, 2023, **125**, doi: 10.1016/j.eneco.2023.106850

[9] 吴伟平,刘雨宁,苏乐言,等.基于人工神经网络的数字经济碳减排及其条件效应[J].生态学报,2025,**45**(11):5229-5245.
Wu W P, Liu Y N, Su L Y, *et al*. Research on carbon emission reduction and its conditional effects of digital economy based on Artificial Neural Networks[J]. Acta Ecologica Sinica, 2025,**45**(11):5229-5245.

[10] 张兵兵,王捷,闫志俊.中国城市碳达峰路径及其驱动因素的结构分解[J].中国人口 资源与环境,2023,**33**(9):38-44.
Zhang B B, Wang J, Yan Z J. Structural decomposition of the paths to achieving the goal of peak carbon emissions and its driving factors in China's prefecture-level cities[J]. China Population, Resources and Environment, 2023,**33**(9):38-44.

[11] Xiong S, Li Y, Li Q, *et al*. Energy consumption prediction by modified fish migration optimization algorithm: City single-family homes[J]. Applied Energy, 2024, **353**, doi:10.1016/j. apenergy.2023.122065.

[12] Feng Z, Zhang J, Jiang H, *et al*. Energy consumption prediction strategy for electric vehicle based on LSTM-transformer framework[J]. Energy, 2024, **302**, doi: 10.1016/j.energy.2024.131780.

[13] 李媛,彭玉玲,彭浩纳,等.基于InVSET-Ridge Regression-PLUS模型的云贵高原碳储量时空演变及多情景预测[J].环境科学，2026，**47**(3),doi：10.13227/j.hjkx.202501105.
Li Y, Peng Y L, Peng H N, *et al*. Spatiotemporal evolution of carbon storage and multi-scenario prediction in the Yunnan-Guizhou plateau based on the InVSET-Ridge Regression-PLUS model[J]. Environmental Science，2026，**47**(3), doi：10.13227/j.hjkx.202501105.

[14] 方心,张成元,柴建,等.考虑多元多尺度特征驱动两阶段参数寻优的煤炭价格预测研究[J/OL].系统工程理论与实践,1-13[2025-08-18].https://link.cnki.net/urlid/11.2267.N.20250425.1652.004.

Fang X, Zhang C Y, Chai J, *et al*. A coal price forecasting method based on multi-factor and multi-scale characteristics driving two-stage parameter optimization[J/OL]. Systems Engineering-Theory & Practice, 1-13[2025-08-18].https://link.cnki.net/urlid/11.2267.N.20250425.1652.004.

[15] Li X, Zhang Y, Chen L, *et al*. A decomposition-ensemble-integration framework for carbon price forecasting[J]. Expert Systems with Applications, 2024, **257**, doi:10.1016/j.eswa.2024.124954.

[16] 孙毅,鲍荟谕,郑顺林,等.基于数据分解与知识蒸馏的多能负荷与碳排放联合预测模型[J].中国电机工程学报, 2025,**45**(20): 7997-8011.
Sun Y, Bao H Y, Zheng S L, *et al*. Multi-energy Load and carbon emission prediction model based on data decomposition and knowledge distillation[J]. Proceedings of the CSEE, 2025,**45**(20): 7997-8011.

[17] Peng T, Zhang C, Zhou J, *et al*. An integrated framework of Bi-directional long-short term memory (BiLSTM) based on sine cosine algorithm for hourly solar radiation forecasting[J]. Energy, 2021,**221**, doi:10.1016/j.energy.2021.119887.

[18] 诸晓骏,薛贵元,徐筝,等.基于双模式分解的非线性集成短期碳排放预测[J].环境科学,2025,**46**(10):6152-6161.
Zhu X J, Xue G Y, Xu Z, *et al*. Nonlinear integrated short-term carbon emission projections based on bimodal decomposition[J]. Environmental Science, 2025,**46**(10):6152-6161.

[19] 褚群微,杨文波,杨占山.基于VMD分解与K-shape聚类的济南市PM2.5浓度预测[J].环境科学学报,2025,**45**(9):86-95.
Chu Q W, Yang W B, Yang Z S.PM2.5 concentration prediction in Jinan City based on VMD decomposition and K-shape clustering[J]. Acta Scientiae Circumstantiae, 2025,**45**(9):86-95.

[20] Chou J S, Limantono D N. Jellyfish Search-optimized wavelet transform-enhanced artificial intelligence for multi-horizon energy consumption forecasting in the Mid-Atlantic region[J]. Energy, 2025, **335**, doi: 10.1016/ j. energy. 2025. 138072

[21] 刘金培,张了丹,陈意,等.文本数据驱动的碳交易价格区间二层分解预测方法[J].管理评论,2023,**35**(12):31-39.
Liu J P, Zhang L D, Chen Y, *et al*. A Two-layer decomposition method with textual data for carbon price interval forecast[J]. Management Review，2023,**35**(12):31-39.

[22] 成润坤,王辉,刘达,等.融合RSDE框架与KAN算法的现货电价异质模型集成预测[J].中国电机工程学报,2024,**44**(24):9645-9658.
Cheng R k, Wang H, Liu D, *et al*. Ensemble prediction of spot electricity prices using heterogeneous models by integrating the RSDE framework and KAN algorithm[J]. Proceedings of the CSEE, 2024,**44**(24):9645-9658.

[23] 杨霞,袁媛,吴婷,等.资源依赖、绿色技术创新与煤炭资源型城市碳排放[J].环境科学, 2026，**47**(7), doi:10.13227/j.hjkx.202504286.
Yang X, Yuan Y, Wu T, *et al*. Resource dependence, green technology innovation, and carbon emission in coal resource based cities[J]. Environmental Science, 2026，**47**(7), doi:10.13227/j.hjkx.202504286.

[24] 曾灿英,韩丹叶,刘庄田,等.区域经济差异背景下中国二氧化碳排放影响因素与减排策略[J].环境科学,2025,**46**(10):6221-6232.
Zeng C Y, Han D Y, Liu Z T, *et al*. Influencing factors and mitigation strategies for carbon dioxide emissions in China under regional economic differentiation[J]. Environmental Science, 2025,**46**(10):6221-6232.

[25] 常永兴,单春艳.中国与碳达峰国家碳排放影响因素比较分析[J].环境科学, 2026，**47**(7),doi：10.13227/ j.hjkx.202504252.
Chang Y X, Shan C Y. Comparative analysis of influencing factors for carbon emissions in China and carbon peak countries[J]. Environmental Science, , 2026，**47**(7),doi：10.13227/ j.hjkx.202504252.

[26] Quan Z, Xu X, Jiang J, *et al*. Uncovering the drivers of ecological footprints: A STIRPAT analysis of urbanization, economic growth, and energy sustainability in OECD countries[J]. Journal of Cleaner Production, 2024, **475**:143686.

[27] 刘泽珺,鞠美庭.基于STIRPAT模型的北方某滨海城市碳达峰情景分析[J].环境科学,2025,**46**(9):5524-5534.
Liu Z J, Ju M T. Scenario analysis of carbon peaking in a northern coastal city based on the STIRPAT model[J]. Environmental Science, 2025,**46**(9):5524-5534.

[28] 黄威翔,高川作,吴波,等.基于STIRPAT模型的广西碳达峰路径[J].环境科学,2025,**46**(2):682-695.
Huang W X, Gao C Z, Wu Bo, *et al*. Development path of Guangxi to reach the carbon emission peak based on STIRPAT model[J]. Environmental Science, 2025,**46**(2):682-695.

[29] 王雪同,鲁垠涛,姚宏,等.中国制造业碳排放影响因素分析及碳达峰预测研究[J].生态经济,2025,41(6):34-40+53.
Wang X T, Lu Y T, Yao H, *et al*. Analysis of the influencing factors of carbon emissions in China's manufacturing industry and prediction of carbon peak[J]. Ecological Economy,2025,41(6):34-40+53.

[30] 李艳颖,蒋语聪,李文,等.基于STIRPAT-LEAP模型的陕西省增汇减排发展路径及驱动因素[J].环境科学, 2026，**47**(2),doi：10.13227/j.hjkx.202502070.

Li Y Y, Jiang Y C, Li W, *et al*. Development path and driving factors of sink enhancement and emission reduction in Shaanxi Province based on STIRPAT-LEAP modeling[J]. Environmental Science, 2026，**47**(2), doi：10.13227/j.hjkx.202502070.

[31] Huang X, Han Y, Yan J, *et al*. Hybrid forecasting model of building cooling load based on EMD-LSTM-Markov algorithm[J]. Energy and Buildings, 2024, **321**, doi:10.1016/j.enbuild.2024.114670.

[32] Yu Q, Yuan H, Liu Z, *et al*. Spatial weighting EMD-LSTM based approach for short-term PM2.5 prediction research[J]. Atmospheric Pollution Research, 2024,**15**(10):102256.

[33] Li N, Dong J, Liu L, *et al*. A novel EMD and causal convolutional network integrated with Transformer for ultra short-term wind power forecasting[J]. International Journal of Electrical Power & Energy Systems, 2023, **154**:109470.

[34] 唐湘博,黄有为,苏涵.基于机器学习的中国农业净碳汇预测模型构建及驱动因素响应分析[J].环境科学,2026，**47**（6），doi: 10.13227/j.hjkx.202504072.
Tang X B, Huang Y W, Su H. Construction and driving factors analysis of a machine learning-based prediction model for net carbon sink in Chinese agriculture[J]. Environmental Science, 2026, **47**（6）, doi: 10.13227/j.hjkx.202504072..

[35] 杨健，曹楠，金大意，等．基于 GWO-XGBoost 模型和 SHAP 值的数据价格预测及可解释性分析 [J/OL]. 计算机科学,1-13[2026-01-13].https://link.cnki.net/urlid/50.1075.TP.20251205.1140.020.
Yang J, Cao N, Jin D Y, *et al.* Data price prediction and interpretability analysis based on Gwo-Xgboost model and SHAP values [J/OL]. Computer Science,1-13[2026-01-13].https://link.cnki.net/urlid/50.1075.TP.20251205.1140.020.

[36] 高晓辉，莫俊文，吴利丰，等．基于有向可见图网络灰色模型的交通 ESG 预测 [J/OL]. 系统工程理论与实践,1-18[2026-01-13].https://link.cnki.net/urlid/11.2267.N.20260107.1605.040.
Gao X H, Mo J W, Wu L F, *et al.* Traffic ESG prediction based on directed visible graph network grey model[J/OL]. Systems Engineering-Theory & Practice, ,1-18[2026-01-13].https://link.cnki.net/urlid/11.2267.N.20260107.1605.040.

[37] Águila-León J, Vargas-Salgado C, Díaz-Bello D, *et al*. Optimizing photovoltaic systems: A meta-optimization approach with GWO-Enhanced PSO algorithm for improving MPPT controllers[J]. Renewable Energy, 2024, **230**, doi: 10.1016/ j.renene. 2024.120892.

[38] Peng S, Wang Y, Tang A, *et al.* State of health estimation joint improved grey wolf optimization algorithm and LSTM using partial discharging health features for lithium-ion batteries[J]. Energy, 2025, **315**, doi: 10.1016/j.energy.2024.134293.

[39] Al-Ibraheemi Z, Al-Janabi S. Sustainable energy: Advancing wind power forecasting with grey wolf optimization and GRU models[J].Results in Engineering, 2024, **24**, doi:10.1016/j.rineng.2024.102930.

[40] Xu Y, Huang X, Zheng X, *et al.* VMD-ATT-LSTM electricity price prediction based on grey wolf optimization algorithm in electricity markets considering renewable energy[J]. Renewable Energy, 2024, **236**, doi:10.1016/j.renene.2024.121408.

[41] 刘敏毅，崔博文，王宇坤，等．基于注意力机制的Transformer模型预测$PM_{2.5}$浓度[J]．环境科学, 2024, **45**(12): 6993-7002.
Liu M Y, Cui B W, Wang Y K, *et al*. Prediction of $PM_{2.5}$ concentration by Transformer model based on attention mechanism[J]. Environmental Science, 2024, **45**(12): 6993-7002.